

六、Theory of Generalization 泛化理论（举一反三）

6.1 Restriction of Break Point 突破点的限制

回顾一下上一章中提到的成长函数 $m_H(N)$ 的定义：假设空间在N个样本点上能产生的最大二分（dichotomy）数量，其中二分是样本点在二元分类情况下的排列组合。

上一章还介绍了突破点（break point）的概念，即不能满足完全分类情形的样本点个数，完全二分类情形（shattered）是可分出 2^N 种二分类（dichotomy）的情形。

继续举例说明，假设一种分类情形最小的突破点为2，即 $k=2$ 。

容易求出在 $N=1$ 时，成长函数 $m_H(N) = 2$

在 $N=2$ 时，成长函数 $m_H(N) < 2^N = 4$ （突破点是2），因此最大的二分类个数不可能超过3，假设为3。

继续观察 $N=3$ 时的情形，因理解稍微有些复杂，还是以图的形式表达，如图6-1所示。

如图6-1a)表示在三个样本点时随意选择一种二分的情况，这种分类没有任何问题，不会违反任意两个样本点出现四种不同的二分类情况（因为突破点是2）；

如图6-1b)表示在a)的基础上，添加不与之前重复的一种二分类，出现了两种不冲突的二分类，此时同样没有任何问题，不会违反任意两个样本点出现四种不同的二分类情况；

如图6-1c) 表示在b)的基础上，再添加不与之前重复的一种二分类，出现了三种不冲突的二分类，此时同样没有任何问题，不会违反任意两个样本点出现四种不同的二分类情况；

如图6-1d) 表示在c)的基础上，再添加不与之前重复的一种二分类，问题出现了，样本 x_2, x_3 出现了四种不同的二分情况，和已知条件中 $k=2$ 矛盾（最多只能出现三种二分类），因此将其删去。

如图6-1e) 表示在c)的基础上，再添加不与之前重复的一种二分类，此时同样没有任何问题，不会违反任意两个样本点出现四种不同的二分类情况；

如图6-1f) 表示在e)的基础上，再添加不与之前重复的一种二分类，问题又出现了，样本 x_1, x_3 出现了四种不同的二分情况，和已知条件中 $k=2$ 的条件不符（最多只能出现三种二分类），因此将其删去。

x_1	x_2	x_3
○	○	○
○	○	○
○	○	×

a) b)

x_1	x_2	x_3
○	○	○
○	○	×
○	×	○

x_1	x_2	x_3
○	○	○
○	○	×
○	×	○
○	×	×

c) d)

x_1	x_2	x_3
○	○	○
○	○	×
○	×	○
×	○	○

x_1	x_2	x_3
○	○	○
○	○	×
○	×	○
×	○	○
×	×	×

e) f)

图6-1 样本数为3时的二分类情形

在突破点是2，样本点为3时，最多只能有四种二分类情况，而 $4 \ll 2^3$ 。

从上述情形，可以做一个猜想，成长函数 $m_H(N)$ 小于等于某个与突破点 k 有关的二次项，如果可以证明这一结论，即能寻找到一个可以取代无限大 M 的数值，同理即能公式4-6在假设空间为无限大时也是成立，即机器是可以学习的。

假设突破点 $k=1$ ，在样本数为3时，最大的二分类个数是多少？答案是1，可以想象，在样本为1时，只有一种分类情形，假设这种情形是正，则以后所有样本也为正，才能满足上述条件，所以样本 N 不论为多少，其最大二分类数都是1。

6.2 Bounding Function - basic function 上限函数的基本情形

根据上一小节的例子，提出一个新的概念，上限函数 $B(N, k)$ (bounding function)，其定义为在最小突破点为 k 时，表示成长函数 $m_H(N)$ 最大值的函数。此函数将成长函数从各种假设空间的关系中解放出来，不用再去关心具体的假设，只需了解此假设的突破点，突破点相同的假设视为一类，抽象化成长函数与假设的关系。

二分类的个数或者称之为成长函数 $m_H(N)$ 说白了就是二元（在图中表示为"x"或者"o"的符号）符号在在长度为 N 的情况下的排列组合（每个不同的排列代表一个二分类，每种二分类可看做一个向量）个数。

在强调一遍，提出这种上限函数的好处在于，它的性质可以不用关心到底使用的是何种假设空间，只需要知道突破点便可以得到一个上限函数来对成长函数做约束。

例如： $B(N, 3)$ 可以同时表示一维空间的感知器（1D perceptrons）和间隔为正（positive intervals）的两种假设空间，因为两者都满足 $k=3$ 。注意一维的成长函数为 $m_H(N) = 2N$ ，而间隔为正的函数为 $m_H(N) = 1/2N^2 + 1/2N + 1$ ， $B(N, 3)$ 一定比这两种情况中最大的还要大，才能约束成长函数，回忆上限函数的定义，是成长函数 $m_H(N)$ 最大值的函数表示，从这个例子中可以理解为何还会出现"最大值"。

想要证明 $B(N, k) < poly(N)$ 。

先观察已知的 $B(N, k)$ 如何表示，通过列表方式找出规律，如图6-2所示。

$B(N, k)$		k						
		1	2	3	4	5	6	...
N	1	1	2	2	2	2	2	...
	2	1	3	4	4	4	4	...
	3	1	4	7	8	8	8	...
	4	1			15	16	16	...
	5	1				31	32	...
	6	1					63	...
	⋮	⋮						⋱

图6-2 已知的 $B(N, k)$ 取值

在 $N=k$ 的这条斜线上，所有值都等于 $2^N - 1$ ，这一原因在上一节推导中已经提到过，原因是突破点代表不能完全二分类的情况，因此在此情况下最大的二分类数可以是 $2^N - 1$ 。在这条斜线的右上角区域所有的点都满足完全二分类的，因此值为 2^N 。

而在斜线右下角上已给出数值的点都是在上一节中已求出答案的点，空白地方的值则是下节需要介绍的内容。

当突破点等于 K 的时候，成长函数的上限成为上限函数，公式如下

$$B(N, k) = \max(m_H(N))$$

6.2 Bounding Function - Inductive Cases 上限函数的归纳情形

这一小节主要是将上一小节空白的内容填写上，从已有的数据上可以看出一个似乎是正确的结论：每个值等于它正上方与左上方的值相加。如公式6-1所示。 $B(N, k) = B(N - 1, k) + B(N - 1, k - 1)$

当然单从观察是无法证明该公式是成立的，以下从结论出发来验证它的正确性。

首先通过计算机求出N=4, k=3 的所有二分情况（自己编写程序加上限制条件，在16个二分类中找出符合条件的），其结果如图6-3所示。

	x ₁	x ₂	x ₃	x ₄
01	○	○	○	○
02	×	○	○	○
03	○	×	○	○
04	○	○	×	○
05	○	○	○	×
06	×	×	○	×
07	×	○	×	○
08	×	○	○	×
09	○	×	×	○
10	○	×	○	×
11	○	○	×	×

图6-3 N=4,k=3的所有二分类

图6-3中的展示效果还是有些混乱，对这11种情况做一次重新排序，将x₄与x₁ x₃ 分开观察，如图6-4所示，橙色部分为x₁ x₃两两一致、x₄成对（pair）出现的二分类，设橙色部分一共α对二分类，即2α种二分类；紫色部分为各不相同的x₁ x₃，设紫色部分一共β种，得公式6-2。 $B(4, 3) = 11 = 2 \times 4 + 3 = 2\alpha + \beta$

	x ₁	x ₂	x ₃	x ₄
01	○	○	○	○
05	○	○	○	×
02	×	○	○	○
08	×	○	○	×
03	○	×	○	○
10	○	×	○	×
04	○	○	×	○
11	○	○	×	×
06	×	×	○	×
07	×	○	×	○
09	○	×	×	○

图6-4 以成对和单个的形式展示

注意 $k = 3$ ，意味着在样本点为3时，不能满足完全二分的情形。需要观察在样本数为3时，这11种分类会有何变化，不妨假设这三个样本是 $x_1 x_3$ ，于是只剩如图6-5所示的7种二分类情形。

	x_1	x_2	x_3
α	○	○	○
	×	○	○
	○	×	○
	○	○	×
β	×	×	○
	×	○	×
	○	×	×

图6-5 三个样本时缩减之后的二分类

其中橙色部分，原本两两成对出现的二分类，在去掉 x_4 所属的那列样本之后，就合并成了4种二分类情况（ $\alpha = 4$ ），紫色部分不变依然为3种二分类情况（ $\beta = 3$ ）。因为已知 $N = 4, k = 3$ ，在样本数为3时，图6-5中即表示样本数为3的情况，其一定不能满足完全二分，因此与 α 与 β 一定满足公式6-3。 $\alpha + \beta \leq B(3, 3)$

继续观察橙色部分的区域，如图6-6所示。

	x_1	x_2	x_3
α	○	○	○
	×	○	○
	○	×	○
	○	○	×

图6-6 三个样本时橙色区域的二分类

以下使用反证法证明。假设 $x_1 x_3$ 三个样本在如上图所示的四种二分类情况下，满足任意两个样本都可完全二分。将 $x_1 x_3$ 中任意两列取出，同之前被删除的 x_4 列相结合，一定可得到一种三个样本都满足完全二分类的情形（因为不论是哪两列与相结合都会得到8种二分类，每一行二分类都对应两个不同标记的，因此为8种。且两列四行的二分类是全完二分的，在此基础上加上不同属性的列，应该也不会重复，因此一定也是全完二分的）。但是此结论和已知任意三个样本不能完全二分冲突了，因此假设不成立，即在图6-6中一定存在某两个样本点不能完全二分的情况，因此得出如公式6-4所示的结论。 $\alpha \leq B$

由公式6-2~公式6-4推导出公式6-5。

$$\begin{aligned}
 B(4, 3) &= 2\alpha + \beta \\
 &= \alpha + (\alpha + \beta) \\
 &\leq B(3, 3) + B(3, 2)
 \end{aligned}$$

最终还能推导出公式6-6的通用结论，也就是开始时公式6-1的猜想。

$$\begin{aligned} B(N,k) &= 2\alpha + \beta \\ &= \alpha + (\alpha + \beta) \\ &\leq B(N-1) + B(N-1,k-1) \end{aligned}$$

根据这一结论将图6-2补齐，如图6-7所示。

$B(N,k)$		k					
		1	2	3	4	5	6
N	1	1	2	2	2	2	2
	2	1	3	4	4	4	4
	3	1	4	7	8	8	8
	4	1	≤ 5	11	15	16	16
	5	1	≤ 6	≤ 16	≤ 26	31	32
	6	1	≤ 7	≤ 22	≤ 42	≤ 57	63

图6-7 补齐后的上限函数表

最后可以通过如下方式证明公式6-7是成立的。

$$B(N,k) = \sum_{i=0}^{k-1} C_N^i$$

首先需要预先了解组合中的一个定理，如公式6-8所示。

$$C_n^k = C_{N-1}^k + C_{N-1}^{k-1}$$

很容易证明K=1 情况下公式6-7成立，如公式6-9所示。

$$B(N,1) = 1 = C_N^0 \leq \sum_{i=0}^{1-1} C_N^i$$

上一节中已经给出了证明，不仅仅是满足不等号条件，而且满足等号。

再使用数学归纳法证明在的情况，公式6-7成立。

假设公式6-10成立，则可以得到在的情况下公式6-11成立，同时结合公式6-6的结论，公式6-12也能被推导出来。

$$B(N-1, k) \leq \sum_{i=0}^{k-1} C_{N-1}^i \quad (\text{公式6-10})$$

$$B(N-1, k-1) \leq \sum_{i=0}^{k-2} C_{N-1}^i = \sum_{i=1}^{k-1} C_{N-1}^i \quad (\text{公式6-11})$$

$$\begin{aligned} B(N, k) &\leq B(N-1, k) + B(N-1, k-1) \\ &\leq \sum_{i=0}^{k-1} C_{N-1}^i + \sum_{i=0}^{k-2} C_{N-1}^i \\ &= \sum_{i=0}^{k-1} C_{N-1}^i + \sum_{i=1}^{k-1} C_{N-1}^i \\ &= C_{N-1}^0 + \sum_{i=1}^{k-1} (C_{N-1}^i + C_{N-1}^i) \\ &= 1 + \sum_{i=1}^{k-1} C_N^i \\ &= C_N^0 + \sum_{i=1}^{k-1} C_N^i \\ &= \sum_{i=0}^{k-1} C_N^i \end{aligned} \quad (\text{公式6-12})$$

这一结果意味着：成长函数 $m_H(N)$ 的上限函数 $B(N, k)$ 的上限为 N^{k-1} 。

6.4 A Pictorial Proof 一种形象化的证明

至此说明了（不敢叫证明）一个在机器学习领域很著名的理论——V-C上界制（Vapnik-Chervonenkis bound）。

2维的感知器，其突破点为4，因此其成长函数为 $O(N^3)$ ，可以使用这个VC上界来说明在样本N足够大时候，发生坏事的情况很少，即选择一个在样本中错误率很小的g，可以得出其在整个数据上错误率也很低的结论，说明机器学习是可能的。